# 何浩源 Hao-Yuan He

18851768896 · hao-yuan-he.github.io

研究关注神经网络与规则推理的结合，以及大语言模型的高效推理与训练。相关成果发表于 **NeurIPS（Spotlight）**、**ICML**、**TPAMI** 和 **Machine Learning**。

## 教育经历

**南京大学 人工智能学院 · LAMDA 实验室** 2021 – 2028

计算机科学与技术博士在读（硕博连读） · 导师：黎铭教授

**南京工业大学** 计算机科学与技术 · 工学学士 2017 – 2021

## 实习与项目

**华为 2012 实验室** 2026.06 – 至今

**LongSpark：长文本场景下的大模型生成加速** 项目主导 · 共同第一作者

- 投机解码先由小模型快速起草一段候选，再由大模型一次并行验证，在加速生成的同时保持大模型自身的输出分布。但文本越长，小模型每轮要读的内容越多，自身随之变慢，逐步抵消加速收益。
- 最终结果由大模型把关，小模型只需保留足以猜准的线索。LongSpark 复用大模型验证时已算出的信息，为小模型提供大小固定、兼顾近处细节与远处要点的上下文，使其每轮开销不随文本长度增长。
- 在 Qwen3-4B/8B/14B 的数学、代码、对话八项基准上，平均吞吐为常规自回归生成的 **1.88–2.13 倍**；在 CodeSpan 的 64K 长代码任务中（Qwen3-8B，并发 16），比 DSpark 提升 **29.1%**。

**Millrace：投机解码小模型的训练调度** 负责调度算法

- 训练投机解码的小模型依赖大模型持续提供学习信息，信息准备与传输不足会让训练设备空等。
- 提前统筹近期所需信息的准备、传输与训练，并按实际进度滚动调整，减少训练等待。受控仿真中（8K–32K 序列，计入规划开销），完成同等训练的耗时比按到达顺序调度缩短约 **27%**，比仅按当前任务排序的优先级调度缩短约 **13%**。

**腾讯 AI Lab** 深圳 2023.05 – 2023.07

《王者荣耀》游戏 AI 研究：将训练流程由 TensorFlow 迁移至 PyTorch，并参与智能体算法研究。

## 代表论文

**神经符号学习的统计可学习性理论** NeurIPS 2025 · Spotlight · 第一作者

神经符号学习结合神经网络与规则推理。仅用最终答案训练时，模型可能答对结果却学错中间概念。本文建立这类学习的统计学习理论框架，给出任务可学习的**充分必要条件**，界定“答对”何时意味着“学对”，并量化所需数据量与学习误差。

**反绎学习中多义解释的不确定性建模** ICML 2024 · 第一作者

反绎学习借助规则，为缺少标注的中间概念推断标签。但同一样本常有多个符合规则的解释，只取其一可能引入错误的训练信号。本文保留候选解释，按其概率构造监督，将不确定性纳入训练，使学习更可靠。

## 荣誉

南京大学优秀研究生 2023、2024　　全国大学生数学竞赛一等奖 2018、2020

首届粤港澳大湾区（黄埔）国际算法算例大赛三等奖 2022，团队